

İSTANBUL BEYKENT ÜNİVERSİTESİ

Bilgisayar Mühendisliği Bölümü · Gelişmiş Veri Tabanı Uygulamaları

Makine Öğrenmesi ve SQL Entegrasyonu

Araştırma Notu

Emir Karaman (2303022018) · Metehan Şener (2303022052) · Sude Nur Karabulut (2503022072)

1. Giriş

Makine öğrenmesi ve SQL entegrasyonu, makine öğrenmesi modellerinin SQL veritabanlarının içinde ya da doğrudan yanında çalıştırılması anlamına gelir. Geleneksel iş akışında veri, analiz için veritabanından dışarı çekilir; ayrı bir Python veya R ortamında model eğitilir; elde edilen sonuçlar tekrar veritabanına yazılır. Bu döngü, hem veri taşınması nedeniyle ek gecikme yaratır hem de verinin sistem dışına çıkması güvenlik riskleri oluşturur. Entegre yaklaşımda ise model verinin bulunduğu yere getirilir ve tahmin, çoğunlukla tanıdık bir SQL söz dizimi üzerinden tetiklenir.

Bu yaklaşımın önemi, verinin bulunduğu yerle doğrudan bağlantılıdır: Gerçek dünyada üretilen verilerin büyük kısmı zaten ilişkisel veritabanlarında saklanmaktadır. Modeli bu verinin yanına taşımak; veri mühendisi ile makine öğrenmesi mühendisi arasındaki koordinasyon yükünü azaltır, SQL bilen geniş bir kullanıcı kitlesinin tahmin üretebilmesini sağlar ve üretim sistemlerine entegrasyonu kolaylaştırır.

2. Geleneksel Yaklaşımın Sınırları ve Entegrasyon İhtiyacı

Veriyi dışarı taşıyan klasik mimaride üç temel sorun öne çıkar. Birincisi, veri hareketi maliyetlidir: büyük tabloların ağ üzerinden taşınması hem yavaştır hem de işlem gücü tüketir. İkincisi, veri veritabanı dışına çıktığında erişim denetimi ve KVKK benzeri uyum gereksinimlerinin sağlanması zorlaşır. Üçüncüsü, eğitim ile üretim ortamlarının ayrı olması; modelin dağıtımını, sürüm yönetimini ve izlenmesini karmaşıktırır.

Bu sorunlar, modeli verinin yanında çalıştıran çözümlere olan ilgiyi artırmıştır. Bununla birlikte, modeli doğrudan veritabanı motoruna gömmek de risksiz değildir: veritabanı sunucusu hem veri yönetimi hem de model eğitimi yükünü taşıdığından kaynak çakışmaları yaşanabilir; karmaşık modellerin veritabanı ortamında yeterince test edilememesi üretim hatalarına yol açabilir. Dolayısıyla doğru mimari seçimi, iş yüküne ve model karmaşıklığına göre yapılmalıdır.

3. Mimari Yaklaşımlar

3.1 Veritabanı-İçi (In-Database) Makine Öğrenmesi

Bu mimaride model doğrudan veritabanı motorunun içinde çalışır; SQL sorgusu hem veriyi çeker hem de modeli tetikler. Eğitim ve tahmin, veritabanından hiç ayrılmadan gerçekleştirilir. Google BigQuery ML, Microsoft SQL Server Machine Learning Services ve PostgreSQL için geliştirilen pgml uzantısı bu kategoriye örnektir. Bu yaklaşımın en güçlü yanı, verinin yerinde kalmasıyla sağlanan düşük gecikme ve yüksek güvenliktir.

3.2 Harici Eğitim + SQL Köprüsü

İkinci yaklaşımda ise model, veritabanının dışında çalışan ortamlarda (örneğin Python veya Apache Spark) eğitilir. Modelin ürettiği tahmin sonuçları daha sonra düzenli ve yapılandırılmış bir şekilde SQL tablolarına aktarılır. Uygulama, sonuçlara SQL üzerinden erişir. MLflow + PostgreSQL veya Spark ML + Hive gibi bileşimler bu yaklaşıma örnektir. Bu yöntem, özellikle derin öğrenme gibi yüksek işlem gücü gerektiren modellerin daha esnek araçlarla eğitilmesini sağlarken, elde edilen sonuçların tekrar ilişkisel veritabanı ortamına aktarılıp sorgulanabilir hale gelmesine imkân verir. Geliştirdiğimiz FintechDB projesi de bu yaklaşımı temel almaktadır.

4. Teknoloji Örnekleri

Aşağıdaki tablo, makine öğrenmesini SQL ile entegre eden başlıca platformları ve bu platformların temel işlevlerini göstermektedir. Tablodan da görülebileceği üzere, hem büyük bulut sağlayıcıları hem de açık kaynak toplulukları, makine öğrenmesi süreçlerini SQL söz dizimine daha yakın hale getirerek tahmin üretimini kolaylaştırmayı amaçlamaktadır.

Platform	Yaklaşım / İşlev	Sahibi
BigQuery ML	SQL ile CREATE MODEL; lineer/lojistik regresyon, XGBoost	Google
SQL Server ML Services	T-SQL içinden Python/R çalıştırma (sp_execute_external_script)	Microsoft
PostgreSQL + pgml	pgml.train() ve pgml.predict() fonksiyonları	Açık kaynak
Oracle Machine Learning	Veritabanı-İçi algoritma kütüphanesi	Oracle
Apache Spark SQL	ML pipeline'ının SQL sorgusuyla tetiklenmesi	Apache
MindsDB	SQL söz dizimi ile model eğitme ve tahmin	Açık kaynak

5. SQL ile Model Oluşturma: Örnek

Aşağıdaki örnek, BigQuery ML söz dizimine benzer bir biçimde, bir müşteri kaybı modelinin doğrudan SQL ile nasıl eğitilip kullanılabileceğini göstermektedir. Veri ile modelin aynı yerde bulunması, hem zaman hem de güvenlik açısından önemli avantaj sağlar.

```
-- 1. Modeli oluştur ve eğit
CREATE MODEL muster_i_kayip_modeli
OPTIONS (model_type = 'logistic_reg') AS
SELECT yas, uyelik_suresi, aylık_odeme, sikayet_sayisi,
       kayip_etti          -- hedef değişken (0/1)
FROM   musteriler;

-- 2. Yeni müşteriler için tahmin yap
SELECT *
FROM   ML.PREDICT(
      MODEL muster_i_kayip_modeli,
      (SELECT yas, uyelik_suresi, aylık_odeme, sikayet_sayisi
       FROM   yeni_musteriler));
```

6. Kullanım Senaryoları

Makine öğrenmesi ve SQL entegrasyonu, verinin yoğun biçimde ilişkisel tabanda tutulduğu sektörlerde özellikle değerlidir:

- **Bankacılık ve fintech:** Müşteri ve işlem verisi zaten SQL'de bulunduğu için, kredi riski skorlaması ve dolandırıcılık tespiti aynı ortamda çalıştırılabilir.
- **E-ticaret:** Satın alma geçmişi üzerinde doğrudan ML sorgusu çalıştırarak ürün tavsiye motoru oluşturulabilir.
- **Sağlık:** Klinik veriler hiç dışarı çıkarılmadan hasta risk tahmini yapılabilir; bu, gizlilik açısından kritiktir.
- **Telekomünikasyon:** Abonelik verisinden gerçek zamanlı müşteri kaybı uyarıları üretilebilir.
- **Üretim:** Sensör verisi ve ML modeli SQL içinde birleştirilerek arıza/bakım tahmini yapılabilir.

7. Avantajlar ve Sınırlılıklar

Entegrasyonun başlıca avantajları; veri hareketinin ortadan kalkmasıyla elde edilen düşük gecikme, verinin veritabanı dışına çıkmamasıyla sağlanan güvenlik, SQL bilen herkesin model kullanabilmesiyle oluşan kolaylık, ETL karmaşıklığının azalması ve operasyonel sistemlerle kolay entegrasyondur.

Buna karşılık bazı sınırlılıklar göz ardı edilmemelidir. Veritabanı-içi yaklaşımlar derin öğrenme (CNN, Transformer gibi) modelleri için genellikle yetersizdir; hiperparametre optimizasyonu kısıtlıdır; hata ayıklama ve model yorumlanabilirliği klasik araçlara göre zordur; her veritabanı bu özelliği desteklemez ve büyük model eğitimlerinde bellek sorunları çıkabilir. Bu nedenle yöntem, hafif/orta karmaşıklıkta modeller ve operasyonel tahmin senaryoları için en uygun çözümdür.

8. Projemizle İlişkisi: FintechDB

Geliştirdiğimiz FintechDB projesi ile, bu araştırma konusunu somut biçimde uygulamayı hedefledik. Kredi başvuru ve hesap verileri SQL Server üzerinde tutulmakta; harici bir Python katmanında Lojistik Regresyon (Logistic Regression) modeli eğitilmekte ve tüm başvurular için üretilen onay/red tahminleri yeniden veritabanındaki `ML_Model_Sonuc` tablosuna yazılmaktadır. Böylece projede, “harici eğitim + SQL köprüsü” mimarisinin bir örneğini oluşturuyoruz: Model esnek ve güçlü bir geliştirme ortamında eğitilirken, elde edilen sonuçlar ilişkisel veritabanı içinde sorgulanabilir hale gelmekte; aynı zamanda mevcut yetkilendirme, raporlama ve transaction altyapılarıyla entegre biçimde çalışabilmektedir.

9. Sonuç

Makine öğrenmesi ile SQL entegrasyonu, verilerin büyük ölçüde ilişkisel veritabanlarında tutulduğu günümüz dünyasında doğal bir ihtiyaç haline gelmiştir. Modeli verinin yanına taşıyan yaklaşımlar; gecikme sürelerini azaltır, güvenliği artırır ve geliştirme süreçlerini daha sade hale getirir. Bu nedenle özellikle bankacılık, e-ticaret ve telekomünikasyon gibi yoğun veri kullanan sektörlerde önemli avantajlar sağlar. Bununla birlikte bu yaklaşım her model türü için ideal değildir. Özellikle derin öğrenme gibi yüksek işlem gücü gerektiren modeller, çoğu zaman harici ortamlarda eğitime ihtiyaç duyar. Bu nedenle en uygun mimarinin belirlenmesinde iş yükü, veri hacmi ve modelin karmaşıklığı birlikte değerlendirilmelidir.

10. Kaynakça

- [1] J. M. Hellerstein, C. Ré, F. Schoppmann, et al., "The MADlib Analytics Library: or MAD Skills, the SQL," Proceedings of the VLDB Endowment (PVLDB), cilt 5, sayı 12, 2012.
- [2] M. Boehm, I. Antonov, S. Baunsgaard, et al., "SystemDS: A Declarative Machine Learning System for the End-to-End Data Science Lifecycle," 10th Conference on Innovative Data Systems Research (CIDR), 2020.
- [3] Microsoft, "SQL Server Machine Learning Services (Python ve R)," Microsoft Learn, 2024. [Çevrimiçi]. Erişim: <https://learn.microsoft.com/sql/machine-learning>
- [4] Google Cloud, "Introduction to BigQuery ML," Google Cloud Documentation, 2024. [Çevrimiçi]. Erişim: <https://cloud.google.com/bigquery/docs/bqml-introduction>
- [5] PostgresML, "PostgresML Documentation: Training and Predicting with SQL," 2024. [Çevrimiçi]. Erişim: <https://postgresml.org/docs>